

合同编号：

技术咨询合同

项目名称：AetherStore AI 原生统一存储平台
（大模型智能体分级记忆管理与智能调度系统）

委托方（甲方）：南京捷云盛软件科技有限公司

受托方（乙方）：南京信息工程大学

推广方（丙方）：南京国家农创中心

签订时间：2026 年 6 月 5 日

签订地点：南京

有效期限：2026 年 6 月 5 日—2027 年 6 月 30 日

填 写 说 明

一、本合同为中华人民共和国科学技术部印制的技术咨询合同示范文本，各技术合同认定登记机构可推介技术合同当事人参照使用。

二、本合同书适用于一方当事人（受托方）为另一方（委托方）就特定技术项目提供可行性论证、技术预测、专题技术调查、分析评价报告所订立的合同。

三、签约一方为多个当事人的，可按各自在合同关系中的作用等，在“委托方”、“受托方”项下（增页）分别排列为共同委托人或共同受托人。

四、本合同书未尽事项，可由当事人附页另行约定，并作为本合同的组成部分。

五、当事人使用本合同书时约定无需填写的条款，应在该条款处注明“无”等字样。

六、合同文本采用 A4 纸，双面打印竖装（左边装订）。

技术咨询合同

委托方（甲方）：南京捷云盛软件科技有限公司

住 所 地：江苏省南京市江北新区行知路 10 号南京国家农
创园科创中心 1645 号

法定代表人：付涛

项目联系人：高元恺

联系方式：13771717783

通讯地址：江苏省南京市江北新区行知路 10 号南京国家农
创园科创中心 1645 号

电话：13771717783 电子信箱：yuankai.gao@jumborca.com

受托方（乙方）：南京信息工程大学

住 所 地：江苏省南京市浦口区宁六路 219 号

法定代表人：陈海山

项目联系人：许小龙

所属院部：计算机学院、软件学院

联系方式：025-58731195

通讯地址：江苏省南京市浦口区宁六路 219 号

电话：13770604146 电子信箱：xlxu@nuist.edu.cn

推广方（丙方）： 南京国家农创中心

住 所 地： 江苏省南京市浦口区行知路 10 号

项目联系人： 曹一龙

联系方式： 13813361622

通讯地址： 江苏省南京市浦口区行知路 10 号

电话： 13813361622 电子信箱： 361315072@QQ.com

本合同甲方委托乙方就 AetherStore AI 原生统一存储平台（大模型智能体分级记忆管理与智能调度系统） 项目进行技术咨询，并支付咨询报酬。双方经过平等协商，在真实、充分地表达各自意愿的基础上，根据《中华人民共和国民法典》的规定，达成如下协议，并由双方共同恪守。丙方作为农业科创平台，对研发成果进行有效推广。

第一条：乙方进行技术咨询的内容、要求和方式：

1. 咨询内容：

（1）大模型智能体分级记忆调度与边缘协同缓存优化。针对当前智能体在长周期交互中上下文极速膨胀、历史记忆召回污染、高并发网络与算力阻塞等核心痛点，以低延迟、高保真、高可用、自适应为核心目标，完成智能体认知记忆底座全链路升级。规范记忆拦截、异步压缩、特征落盘、冷热路由全流程交互行为，降低底层算力消耗，提升系统整体并发调度效率。1）记忆解耦与语义重构。全面盘点智能体多轮对话上下文，拆解工作记忆与情景记忆的流转路径，引入异步非阻塞流水线与词元级信息熵蒸馏机制，重构高实体密度的精简记忆

模型。2) 动态路由与协同机制建设。制定基于艾宾浩斯时间衰减的冷热分层规范、异构向量底座落盘规则、边缘节点算力下推与缓存淘汰办法，形成统一的端云调度依据，实现“热数据极速直出，冷数据降权唤醒”。

(2) 围绕语义层与智能分层解析总体架构、技术路线，开展方案设计、开发实施和测试工作；

(3) 围绕 Embedding 下推，Agent 记忆管理器以及语义智能分层调度器的设计、开发和测试工作；

(4) 配合甲方完成测试验证、阶段性评审及成果交付工作，并提交双方确认的相关技术文档、代码成果或测试材料。

(5) 应达到的功能指标和技术参数：1) 存储侧旁路向量化与请求拦截机制，摒弃应用端集中式向量化的传统模式，在每个存储节点旁路部署轻量级 Sidecar 服务，对底层数据读写该服务请求直接拦截，保证向量化吞吐稳定吞吐 $\geq 2,000$ QPS。2) SIMD 指令集深度优化的 CPU 向量化内核，针对底层节点特定的通用微架构实施算子级深度优化，依托硬件原生指令集，实现密集矩阵乘法计算与注意力机制的指令级并行化；3) 双库解耦的冷热异构分级存储架构，摒弃传统的单向量库直连模式，对工作记忆与情景记忆进行物理解耦。以高性能内存数据库为核心构建短时工作记忆层，承载高频交互中的易失性实时对话上下文；以向量数据库为核心构建长时情景记忆层。达到短期工作记忆核心接口响应延迟达 $P99 < 10$ ms。4) 非研究基于分布式任务队列 (Celery) 的平滑卸载机制。将耗时的文本特征提纯任务下沉至后台，

依托轻量级词元分类算法，实现 Token 级别的语义蒸馏，实现长期记忆体积实现 $\geq 5x$ （5 倍） 的物理压缩。5)离散化时间衰减的动态调度机制,引入认知心理学经典的艾宾浩斯遗忘曲线模型，设计自适应的时间衰减算子。借助矩阵加速计算，为每条持久化记忆动态附加融合时间戳与唤醒频次的衰减标量，重构向量检索的评分函数。6)多维语义热度感知机制，系统能够根据数据在推理过程中的语义贡献程度，自适应区分高价值热数据与低价值冗余数据，为后续冷热迁移与层级调度提供动态决策依据。7)语义驱动的预测式调度机制,系统能够根据语义亲近度与任务演化趋势，提前完成潜在热点数据的层级调整与热层驻留，降低长上下文场景中的跨层访问延迟与重复加载开销。

2. 咨询要求：（1）乙方应根据甲方提供的项目资料、技术需求和工作条件，围绕本合同约定内容开展相关技术咨询及实施工作；
（2）乙方提交的成果应与双方确认的项目目标和工作安排相符，成果形式包括但不限于技术文档、代码成果或测试材料。

3. 咨询方式：双方可通过现场会议、线上会议、电子邮件、项目协作工具或双方认可的其他方式进行沟通 and 成果确认。

第二条：乙方应当按照下列进度要求进行本合同项目的技术咨询工作：（1）2026 年 6 月 5 日—2026 年 8 月 31 日，完成项目需求确认、资料收集、总体架构设计、技术方案论证及实施计划制定工作，并提交相关方案设计成果。

（2）2026 年 9 月 1 日—2026 年 12 月 1 日，围绕 AetherEngine 语义层与智能分层调度中的 Embedding 下推，Agent 记忆管理器以及语义

智能分层调度器模块，开展方案设计、开发实施、接口对接工作。

（3）2026 年 12 月 2 日—2027 年 2 月 28 日，针对极端长文本和特殊指令集进行边缘极限优化，处理异常断连与吞吐抖动。

2.语义智能分层调度器根据前期积累的训练数据，构建及训练序列预测模型。

（4）2027 年 3 月 1 日 — 2027 年 6 月 30 日 完成相关模块的测试验证、阶段性评审和成果确认，并提交技术文档、代码成果、测试材料或其他相关成果。

第三条：为保证乙方有效进行技术咨询工作，甲方应当向乙方提供下列协作事项：

1. 提供技术资料：

2. 提供工作条件：

（1）为乙方开展技术咨询提供必要的项目背景介绍、技术交流窗口和项目联系人。

（2）根据咨询工作需要，提供必要的开发环境、测试环境、样例数据、访问权限或脱敏后的技术资料。

（3）组织甲方技术人员参与需求澄清、方案评审、阶段验收和成果确认；

（4）按照合同约定及时支付技术咨询费。

3. 其他

4. 在本合同有效期内，乙方应派出专业技术人员为甲方提供技术服务。技术服务人员名单见《技术服务人员表》：

姓名	单位	性别	出生年月	职称或职务	专业	承担的主要工作
----	----	----	------	-------	----	---------

许小龙	南京信息工程大学	男	1988.08	教授	计算机科学与技术	项目负责人
伏舒存	南京信息工程大学	男	1994.09	助理研究员	计算机科学与技术	项目负责人
程勇	南京信息工程大学	男	1980.09	正高级工程师	计算机系统结构	架构设计
项昊龙	南京信息工程大学	男	1993.06	助理研究员	计算机科学与技术	系统实现
孟柯	南京信息工程大学	男	1996.08	博士研究生	计算机应用技	系统实现
杨威	南京信息工程大学	男	2000.01	博士研究生	计算机应用技	系统实现
陈杰	南京信息工程大学	男	1999.03	博士研究生	计算机应用技	系统实现
朱士昊	南京信息工程大学	男	1997.03	博士研究生	计算机应用技术	系统实现
鲁帆	南京信息工程大学	男	1998.10	博士研究生	计算机应用技术	系统实现
姚斌	南京信息工程大学	男	2000.11	博士研究生	计算机科学与技术	系统实现
陈海洋	南京信息工程大学	男	2002.12	博士研究生	计算机应用技术	系统实现
芮子舜	南京信息工程大学	男	2002.04	博士研究生	计算机应用技术	系统实现
王佩司	南京信息工程大学	男	2003.07	硕士研究生	软件工程	系统实现
谭旭梁	南京信息工程大学	男	2002.09	硕士研究生	软件工程	系统实现
肖宇	南京信息工程大学	男	2003.10	硕士研究生	软件工程	系统实现
马剑杰	南京信息工程大学	男	2003.04	硕士研究生	软件工程	系统实现
张涵	南京信息工程大学	男	1998.01	硕士研究生	软件工程	系统实现
陈凯	南京信息工程大学	男	2002.12	硕士研究生	软件工程	系统实现
杨鹏通	南京信息工程大学	男	2004.04	硕士研究生	软件工程	系统实现

第四条： 甲方向乙方支付技术咨询费及支付方式为：

1. 技术咨询费总额为： 650,000 元（大写：人民币陆拾伍万元）
2. 技术咨询费由甲方 分期 （一次或分期）支付乙方。

具体支付方式和时间如下：

签订合同后 7 个工作日支付项目首付款，付款比例：甲方支付技术咨询费总额的 30%，即人民币 195,000 元（大写：人民币拾玖万伍仟元整）。

（1）6月5日-8月31日，1.Embedding 下推完成 Sidecar 旁路拦截架构设计，完成基础矩阵乘法的 SIMD 指令集预研。验收指标:Sidecar 服务能够成功拦截读写请求并返回向量；单核算子通过单元测试。2.Agent 记忆管理器完成搭建 Redis + Milvus 双库物理环境；部署 Celery 异步队列；引入并测试轻量级词元分类算法。验收指标:双库环境能正常连通读写；Celery 能够离线异步处理长文本。

（2）9月1日到12月1日，1.Embedding 下推完成 Sidecar 与存储节点绑定；深度优化 SIMD 算子级并行计算。验收指标:旁路拦截+向量化整体吞吐量在压测环境下稳定 $\geq 2,000$ QPS。2. Agent 记忆管理器完成将艾宾浩斯时间衰减算子封装入 Milvus 检索评分函数；完成异步提纯任务与大模型前台对话的解耦。验收指标：1. 前台 Redis 短期工作记忆接口响应延迟 $P99 < 10$ ms。2. 后台 Celery 压缩流水线实现长记忆体积 $\geq 5x$ 物理压缩。3. 语义智能分层调度器完成构建数据集，将多维语义热度感知机制接入 Agent 组的异构存储。验收指标：1. 数据集质量与数量基本满足模型训练。2. Agent 可以根据提供的热度感知进行记忆分库。在 12 月 1 日形成一个 mvp 版本，系统能够作为一个完整的端到端服务运行。完成大模型发起对话->拦截->异步提纯->向量化->双库分流->带时间衰减的联合检索的基本流程。

付款比例：甲方支付技术咨询费总额的 40%，即 260,000 元（大写：人民币贰拾陆万元整）。

（3）12 月 2 日 - 次年 2 月 28 日，1.Embedding 下推，针对极端长文本和特殊指令集进行边缘极限优化，处理异常断连与吞吐抖动。

2.语义智能分层调度器根据前期积累的训练数据，构建及训练序列预测模型。验收指标：系统能够根据当前对话上下文，提前预测并把 Milvus 中的潜在热点数据“预热”到 Redis 中，缓存命中率要求比 MVP 阶段的启发式算法提升 10%+。

付款比例：甲方支付技术咨询费总额的 20%，即 130,000 元（大写：人民币拾叁万元整）。

（4）次年 3 月 1 日 - 6 月 30 日，对系统进行整体测试，主动注入节点宕机、网络延迟，验证 Sidecar 容灾与双库降级策略。验收标准：满足所有硬性指标并在生产级环境下无故障运行 72 小时。全套标准规范文档齐备。

付款比例：甲方支付剩余技术咨询费总额的 10%，即 65,000 元（大写：人民币陆万伍仟元整）。

里程碑	时间窗	时长	阶段主题	关键成果
M0	2026-06	冻结 AI 原语 SDK 接口 v0.1、调度状态 API、trace 收集与脱敏方案	M0	2026-06
M-MVP	2026-09-01	B1 Sidecar (CPU+SIMD) + B2 Working/Episodic v1 + B3 启发式调度器；端到端记忆服务可运行	M-MVP	2026-09-01
M1 迭代一	2026-12-01	B1 ONNX+OpenVINO、B2 Ebbinghaus 衰减 v1、B3 Phase2 Contextual Bandit (A/B 10% 灰度)	M1 迭代一	2026-12-01
M2 迭代二	2027-02-28	B3 Phase3 Deep RL+GNN 预取 (A/B 50%)、B2 个性化遗忘曲线、B1 可选 GPU 通道	M2 迭代二	2027-02-28
GA	2027-06-30	B3 RL 全量上线 + 一键回退；B2 长期记忆压缩比	GA	2027-06-30

里程碑	时间窗	时长	阶段主题	关键成果
		≥5x; 开源 trace 数据集		

乙方开户名称、银行账号和开户银行为：

开户名称： 南京信息工程大学

银行账号： 10115401040000228

开户银行： 中国农业银行股份有限公司南京市盘城支行

第五条： 双方确定因履行本合同应遵守的保密义务如下：

甲方：

1. 保密内容（包括技术信息和经营信息）：乙方向甲方提供的技术方案、代码成果、技术文档、测试材料、技术路线、算法实现、研究方法、阶段性成果及双方确认应保密的其他信息。

2. 涉密人员范围：参与设计本项目及接触项目资料的人员；

3. 保密期限：2 年。

4. 泄密责任：承担赔偿责任，具体赔偿办法见第八条。

乙方：

1. 保密内容（包括技术信息和经营信息）：甲方向乙方提供的项目资料、技术需求、系统架构、接口文档、代码资料、测试数据、业务数据、客户信息、商业计划、未公开研发成果及双方确认应保密的其他信息。

2. 涉密人员范围：参与设计本项目及接触项目资料的人员；

3. 保密期限：2 年。

4. 泄密责任：承担赔偿责任，具体赔偿办法见第八条。

第六条：本合同的变更必须由三方协商一致，并以书面形式确定。但有下列情形之一的，一方可以向其他两方提出变更合同权利与义务的请求，其他两方应当在14日内予以答复；逾期未答复的，视为不同意该变更，原合同条款继续有效，三方可另行书面协商。

第七条：甲乙双方确定，按以下标准和方式对乙方提交的技术咨询工作成果进行验收：

1. 乙方提交技术咨询工作成果的形式：共同申请 2 项国内发明专利，共同撰写并投稿 1 篇 SCI 检索论文、源代码、架构设计文档、API/接口文档、部署运维手册、用户手册、测试报告。

2. 技术咨询工作成果的验收标准：实现合同所列功能指标和技术指标；交付的清单齐全且可复现构建。

3. 技术咨询工作成果的验收方法：乙方提交成果及自测报告后，甲方在 15 个工作日内组织书面验收与复测并出具书面意见；验收不通过的，甲方一次性书面列明问题，乙方在 10 个工作日内整改后提请复验，复验仍不通过的按违约处理。

4. 验收的时间和地点：由甲方指定。

第八条：

甲乙双方均对本协议的性质和内容有了充分了解，对违约造成的损失和责任以及缔约过失责任已经有了充分的考虑。甲乙双方为了避免承担不可预见的法律责任，根据《中华人民共和国民法典》第五百八十四条关于当事人一方不履行合同义务或者履行合同义务不符合约定，造成对方损失的，损失赔偿额不得超过违约一方订立合同时预见

到或者应当预见到的因违约可能造成的损失之规定，慎重决定：

甲乙双方的责任限定为特定范围，超过部分的损失视为不能预见的损失范围，损失一方放弃追索权，对方不承担赔偿责任。

甲乙双方确定，按以下约定承担各自的违约责任：

1. 乙方逾期交付的，每逾期一日按合同总额的 0.5%向甲方支付违约金，违约金累计达合同总额 10%时，甲方有权解除合同并要求乙方返还已付款项及赔偿损失。

2. 乙方交付成果经两次验收（含复验）仍不合格的，视为根本违约，甲方有权解除合同，乙方返还已收全部款项，并按合同总额 20%支付违约金。

3. 乙方未经甲方书面同意擅自转委托，或违反保密、知识产权约定的，每次按合同总额 10%支付违约金，并赔偿由此造成的全部损失。

4. 甲方无正当理由逾期付款的，每逾期一日按应付未付款项的 0.05%向乙方支付违约金。

第九条：甲乙双方确定，甲方按照乙方符合本合同约定标准和方式完成的技术咨询工作成果做出决策并予以实施所造成的损失，乙方不承担责任。

第十条：甲乙双方确定：

1. 在本合同有效期内，甲方利用乙方提交的技术咨询工作成果所完成的新的技术成果，归 双 （甲、双）方所有。

2. 在本合同有效期内，乙方利用甲方提供的技术资料和工作条件所完成的新的技术成果，归 双 （乙、双）方所有。

1. 乙方为履行本合同开发、交付的全部源代码、技术文档、软件成果

及阶段性成果，其所有权、著作权、专利申请权及其他知识产权，自甲方支付该阶段相应款项之日起完全、排他性地归双方所有；乙方及其人员不得擅自使用、复制、对外提供、转让或开源。

2. 乙方利用甲方提供的资料、数据、需求或环境所形成的任何成果，知识产权归双方所有。

3. 学术发表与署名：乙方如需就本项目发表论文、申请专利或对外署名，须事先取得甲方书面同意，且不得披露甲方的系统架构机密、商业秘密与未公开数据，不得包含可还原核心实现的代码；专利申请权归甲方，乙方可作为发明人署名。论文/专利的数量、级别、署名顺序及单位由双方在附件中另行书面确认。乙方可依法使用开源软件、第三方组件及 AI 辅助开发工具完成项目开发，并保证交付成果满足合同约定要求。

4.甲乙双方对技术成果有特殊用途时，根据双方协商，技术成果可归一方所有（单独署名）。

第十一条：甲乙双方确定，在本合同有效期内，甲方指定 高元恺

为甲方项目联系人，乙方指定 许小龙 为乙方项目联系人。项目联系人承担以下责任：

1. 协调双方资源，推进项目正常运转。
2. 报告合同执行情况。

一方变更项目联系人的，应当及时以书面形式通知另一方。未及时通知并影响本合同履行或造成损失的，应承担相应的责任。

第十二条：甲乙双方确定，出现下列情形，致使本合同的履行成为不必要或不可能的，可以解除本合同：

1. 发生不可抗力；
2. 乙方根本违约（如逾期交付违约金达上限、两次验收仍不合格、擅自转委托或严重泄密）；
3. 甲方无正当理由逾期付款超过 60 日且经催告仍不支付。

第十三条：甲乙双方确定，甲方应在合同到期或乙方履行完本合同约定的义务后15日内向乙方出具3、验收证明。

1. 鉴定意见；2. 采纳意见；3. 验收证明；4. 同意结项证明。

第十四条：甲乙双方因履行本合同而发生的争议，应协商、调解解决。协商、调解不成的，确定按以下第1种方式处理：

1. 提交南京仲裁委员会仲裁；
2. 依法向人民法院起诉。

第十五条：甲乙双方确定：本合同及相关附件中所涉及的有关名词和技术术语，其定义和解释如下：无。

第十六条：与履行本合同有关的下列技术文件，经甲乙双方确认后，设计方案为本合同的组成部分：

第十七条：甲乙双方约定本合同其他相关事项为：双方确认：

1.本合同虽采用技术咨询合同示范文本，但其标的为乙方为甲方开发并交付大模型智能体分级记忆管理与智能调度系统相关软件成果，双方一致同意本合同性质为技术开发（委托）合同，凡涉及成果交付、质量保证、风险负担及知识产权归属等事项，均按《中华人民

中华人民共和国民法典》技术开发合同的有关规定及本合同的特别约定执行；
本合同示范文本中与技术开发合同性质相抵触的格式条款（含第九条
免责约定）不予适用。

2.未经甲方事先书面同意，乙方不得将本合同项下主要开发与交
付工作的全部或部分转委托给任何第三方。乙方参与本项目的全体人
员（含教师、研究生、联合培养及临时人员）均应受本合同保密与知
识产权条款约束，乙方应与其签署相应承诺并对其行为向甲方承担连
带责任；上述人员的变更不得影响项目进度与成果质量。

第十八条：本合同一式 陆 份，具有同等法律效力。

第十九条：本合同经三方签字盖章后生效。

（以下无正文）

甲方：_____（盖章）

法定代表人 / 委托代理人：_____（签名）

年 月 日

乙方：_____（盖章）

法定代表人 / 委托代理人：_____（签名）

年 月 日

印花税票粘贴处:

(此页由技术合同登记机构填写)

合同登记编号:

[illegible]

1. 申请登记人: _____

2. 登记材料: (1) _____

(2) _____

(3) _____

3. 合同类型: _____

4. 合同交易额: _____

5. 技术交易额: _____

技术合同登记机构（印章）

经办人：

年 月 日